

대용량 거시·금융 자료를 이용한 원/달러 환율 변동의 예측력 평가

전찬우(상명대학교 경제금융학부 학사)

박민지(상명대학교 경제금융학부 학생)

이지원(상명대학교 경제금융학부 학생)

이동진(상명대학교 경제금융학부 교수)

<https://doi.org/10.26588/kdic.2022.23.1.004>

대용량 거시·금융 자료를 이용한 원/달러 환율 변동의 예측력 평가*

전찬우**, 박민지***, 이지원****, 이동진*****

〈초 록〉

본고에서는 광범위한 국내외 정보 변수를 활용하여 선형 및 비선형 예측 기법을 통한 원/달러 환율 변동의 예측력을 평가하였다. 선형 기법으로는 능형 회귀, LASSO, Elastic-Net과 동태 요인 모형을 사용하였고 비선형 모형으로는 순환 인공신경망의 하나인 LSTM 기법을 사용하였다. 이와 함께 선형, 비선형 모형을 결합한 예측 조합 방식의 예측력도 분석하였다. 93개의 월별 자료를 정보 변수로 하여 2004년 1월부터 2019년 12월까지의 자료를 대상으로 분석한 결과 예측시계 3개월 이내에서는 대용량 자료를 이용한 모형의 예측력이 벤치마크 모형인 ARIMA 예측보다 우수하였다. LSTM 기법보다는 선형모형의 예측력이 더 우수한 것으로 분석되었으나 예측 시계에 따라 상대적 예측력은 상이한 모습을 보였다. 예측 조합 방식을 사용할 경우 모든 단기 시계에서 안정적으로 가장 우수한 예측력을 보여 단기 예측의 유용성이 높은 것으로 분석되었다.

핵심주제어: 능형 회귀, 대용량 자료, 인공신경망, 원/달러 환율, 예측 조합, LASSO, Elastic-Net
(Ridge, Large Data, Artificial Neural Network, won/dollar exchange rage,
Predictive combination, LASSO, Elastic-Net)

JEL: C53, C55, F31

접수일(2021년 10월 19일), 수정일(2021년 11월 22일), 게재확정일(2022년 5월 24일)

* 본 연구는 상명대학교 LINC+ 사업단의 지원을 받아 진행되었습니다.

** (제1저자) 상명대학교 경제금융학부 학사, jcw050@naver.com

*** (공동저자) 상명대학교 경제금융학부 학생, 4ekfo@naver.com

**** (공동저자) 상명대학교 경제금융학부 학생, supwon0305@naver.com

***** (교신저자) 상명대학교 경제금융학부 교수, rheedj@smu.ac.kr, 02-2287-6123

I. 머리말

소규모 개방경제에서 환율 안정은 금융 안정에 매우 중요한 요인이 된다. 특히 우리나라와 같이 GDP에서 수출과 수입이 차지하는 비중이 매우 큰 여건에서 환율의 금융시장에 미치는 영향은 더욱 크다고 할 수 있다. 시장 규모로는 충분함에도 2000년대 후반 MSCI 선진국 지수 및 WCBI 편입을 포기한 데에도 편입 조건인 역외 외환시장 설립 시 외환시장 불안정성 우려가 가장 큰 요인으로 작용한 바 있다. 최근 정부가 MSCI 선진지수 편입을 재추진하면서 다시 역외 시장이 추진될 경우 환율 안정성의 중요성은 더욱 커질 수 있다. 따라서 환율 시장을 적절하게 모니터링하고 예측하는 것은 우리 금융시장에서 더욱 중요한 역할을 차지할 것으로 보인다. 금융변수의 기능과 실물 교역에서 가격의 기능을 모두 가진 환율에 대한 예측은 항상 중요한 연구 대상이었으나 금융시장과 실물시장의 정보를 모두 가지고 있는 이유로 인해 현재까지도 구조 모형에 의한 예측이 가장 어려운 변수 중의 하나로 남아 있다. 특히 선물환 거래, 거시 분석을 위한 Nowcasting 등에서 예측의 활용도가 높은 6개월 미만의 단기 시계열에서 구조 모형에 기반한 환율의 예측력이 단순 시계열 모형에 비해 낮은 것으로 분석되고 있다. Meese and Rogoff(1983) 이후 많은 연구가 구매력평가설(PPP)이나 이자율 평형, 구조적 벡터 오차 수정 모형 등의 구조 모형을 이용하여 환율의 예측력을 개선하고자 하였으나 여전히 단기 시계열에서는 단순 시계열 모형인 ARIMA(Autoregressive Integrated Moving Average) 모형보다 확실하게 우수한 예측력을 보여주고 있지는 못하다(Ince, 2014). 국내에서도 조우길·모수원(1996), 오문석·이상근(2000), 이상래(2005), 한정아·안창호(2019) 등이 여러 구조 모형의 원/달러 환율에 대한 예측력을 평가하였으나 단기 시계열에서 ARIMA보다 우월한 증거는 찾지 못하였다. 최근에는 시계열 자료의 누적도가 높아지면서 대용량 시계열 자료의 접근이 가능해짐을 통해 구조 모형 대신 대용량 자료의 비구조적 모형에 기반한 경제, 금융 시계열 변수들의 예측에 관한 연구들이 이루어지고 있다. 환율에 관한 연구에서도 Panda and Narisimhan(2006), Dautel, Härdle, Lessmann, and Seow(2020), 서종덕(2016) 등이 기계학습 기법을 이용하여 예측 시계 일주일 이하에서는 환율의

예측력을 개선할 수 있음을 보이고 있다. Leung, Chen, and Daouk(2000), 김영철·이현준·김지우·안재준(2018)는 예측시계 1개월 이상에서 기계학습 기법의 활용 가능성을 평가하였으나 단순히 예측력이 있는지 없는지를 평가한 것이어서 기계학습이 기존 예측 모형들보다 우수한 지에 대한 평가는 제시하지 않았다. 따라서 아직까지 예측시계 1-6개월 사이의 초단기 예측에서 대용량 자료 또는 기계학습을 통해 환율의 예측력을 개선할 수 있는지에 대한 평가는 아직도 제대로 이루어지지 않고 있다.

본고에서는 대용량 자료를 이용한 통계적 기법에 기반하여 월별 원/달러 환율 변동의 예측력을 비교 분석하였다. 기존 연구와 대비되는 본고의 특징은 다음과 같다. 첫째, 입수 가능한 93개의 대용량 자료를 이용하여 예측 모형을 구축하였다. 인공지능망 기법 위주로 분석된 기존 비구조 모형 예측에서는 소수의 정보 변수만을 활용하여 모형을 학습시킴에 따라 거시, 금융 분야에서 빠른 속도로 누적되고 있는 대용량 자료의 활용도가 제한적이었다. 본고에서는 비구조 예측 모형의 장점을 적극 활용하기 위해 실시간으로 입수 가능한 대용량 변수를 활용하여 환율 변동의 단기 예측력을 제고하고자 하였다. 둘째, 선형과 비선형 기법 모두를 적용하여 환율의 예측력을 점검하였다. 선형모형으로는 대표적인 비구조 모형인 능형 회귀(Ridge Regression), LASSO(Least Absolute Shrinkage and Selection Operator), Elastic-Net 방식과 함께 최근 대용량 자료에 많이 활용되고 있는 동태 요인 모형 (Dynamic Factor Model: DFM) 기법을 활용하였다. 비선형 기법으로는 LSTM(Long Short-Term Memory Model)을 중심으로 분석하였다. 대용량 자료의 활용과 관련해선 주로 비선형 방식인 기계학습이 주로 사용되나 일별 자료에 비해 학습 자료의 수가 충분치 않은 월별 시계열 자료에서는 기계학습 방법이 우수한 예측력을 나타내지 못하고 있다. 이를 반영하여 기계학습과 함께 선형 비구조 모형을 같이 검토하였다. 셋째, 선형 및 비선형 예측치를 종합한 예측 조합 방식을 사용하여 예측력 개선 여부를 점검하였다. 정보 변수의 활용방식이 다른 선형모형과 비선형 모형의 예측을 결합하였을 때 예측력의 개선이 나타나는지를 예측 조합 방식으로 평가하였다. 예측 모형의 상대적 예측력을 평가하기 위한 벤치마크 모형으로는 기존 연구에서 가장 예측력이 높은 것으로

분석된 ARIMA 모형으로 설정하였다.

2004. 1월부터 2019. 12월까지의 월별 자료를 이용하여 분석한 결과 선형 기법을 이용한 예측은 모형의 종류에 상관없이 3개월 이하의 단기 시계에서 벤치마크 모형보다 우수한 예측력을 나타냈으며 1개월 뒤 예측에서는 20% 내외의 RMSE 개선을 보였다. 가장 예측력이 우수한 모형은 예측 시계 별로 상이하였으며 예측 기여도가 높은 정보 변수도 예측 시계별로 다른 모습을 보였다. LSTM 기법을 이용한 예측 역시 단기 시계에서 ARIMA 모형보다 높은 예측력을 보였으나 전반적인 RMSE 수준은 선형 모형보다 높은 것으로 나타났다. 예측 조합 방식을 사용할 시 모든 단기 시계에서 안정적으로 가장 우수한 예측력을 보여 단기 예측의 유용성이 높은 것으로 분석되었다.

논문의 구성은 다음과 같다. 2절에서는 환율 예측에 관한 선행연구를 검토하였다. 3절에서는 본고에서 사용한 예측 기법을 소개하였다. 4절에서는 예측 결과를 평가하였으며 마지막 5절에서는 결론을 제시하였다.

II. 선행연구

거시경제에 변화를 가져오는 환율의 변동은 경제 전반에 큰 영향을 주는 변수이다. 따라서 환율을 실제 관측치와 밀접하게 예측하려는 연구는 오래전부터 진행되어왔다. 그러나 환율은 많은 변수에 의해 변동이 일어나기 때문에 실제 환율의 예측에는 어려움이 있다. 기존에는 이자율 평형 모형, PPP 모형을 사용하여 환율을 예측하였지만, 이 모형들이 ARIMA보다 예측력이 좋은지는 여전히 논란이 야기되고 있다. 또한, 모형에 근거한 예측이 ARIMA의 예측력을 이기지 못한 선행연구들이 존재한다. Meese and Rogoff(1983)는 환율 결정이론의 구조적 모형인 신축가격 모형, Hooper-Morton의 종합 모형, 실질이자율 모형과 랜덤워크로 표본 외 예측력을 비교하는 연구를 진행하였다. 연구 결과 랜덤워크의 예측력이 가장 우수하였고 구조적 모형은 환율 예측에 사용하는데 랜덤워크보다 실용성이 떨어진다고 주장하였다. 조우길, 모수원(1996)은 오차 수정 모형을 이용하여 캐나다, 독일, 일본을 분석 대상으로 한 대미 달러 환율의 예측력을 분석한 결과 랜덤워크 모형이 단기 예측력에서 가장 우월하다는 결과가 나왔다. 오문석, 이상근(1999)은 ARIMA 모형과 실질이자율차 모형으로 다중 전이 함수 모형을 설정하여 원/달러 환율의 1개월 표본 내·외 예측력을 평가하였으나 여전히 랜덤워크 모형이 가장 우수한 것으로 나타났다. Ince(2014) 역시 구매력 가설에 따른 예측이 예측시제 16분기 이후에서야 예측력이 높은 것으로 분석하였다. 오문석, 이상근(2000)은 신축가격 화폐 모형, 실질이자율차 모형, 종합모형, 랜덤워크 모형, ARIMA 모형의 원/달러 장단기 환율의 표본 내·외 예측력을 비교하였다. 표본 외에서는 1, 3개월, 표본 내에서는 모든 기간에서 랜덤워크 모형의 예측력이 가장 정확하다는 결과가 나왔다. 이상래(2005)는 단순 랜덤워크 모형, 신경망 모형, ARIMA 모형의 예측력을 비교·분석하였고 변동환율제 구간에서 ARIMA 모형의 예측력이 가장 우수하다는 것을 증명하였다. 한정아·안창호(2019)도 여러 모형의 예측력을 평가하였으나 ARIMA(3, 1, 0) 모형의 예측 값이 유의하였다는 것을 검증하였다.

최근에는 이론에 기반하지 않은 통계적 기법으로 환율을 예측하는 분석들이

활발히 이루어지고 있다. Leung, Chen, and Daouk (2000)은 일반회귀 신경망을 통해 월별 캐나다 달러, 엔화, 영국 파운드화의 예측력을 분석한 결과 랜덤워크 모형보다 우수한 예측력을 가지는 것으로 평가하였다. Panda and Narisimhan (2006)는 인공신경망 기법의 루피화에 대한 1주 뒤 예측력을 평가한 결과 ARIMA 모형과 임의 보행 보다 우수한 예측력을 보인 것으로 분석하였다. Dautel, Härdle, Lessmann, and Seow (2020)은 심층 신경망의 환율 예측 가능성을 시험해 보았으나 일반적 상황에서 단순 신경망에 비해 우수한 예측력을 나타내지 못하였다. 국내에서도 비슷한 연구가 진행되어 왔다. 서종덕(2016)은 랜덤 포레스트 모형과 금융시장 시계열 자료의 변동성을 반영할 수 있는 GARCH 모형을 결합한 모형으로 2010년 7월 1일부터 2014년 6월 30일까지의 일별 자료를 이용하여 결합한 모형이 환율 예측력을 향상시키는지 분석하였다. 또한, 환율 변화에 영향을 미치는 경제 변수들을 선별하고 이들의 중요도에 대한 분석도 진행하였다. RMSE 값을 계산해 본 결과 AR 모형, 랜덤 포레스트 모형보다 혼합모형의 예측력이 높게 나타났음을 확인하였다. 김영철·이현준·김지우·안재준 (2018)은 다층 퍼셉트론 모형으로 3개월 후의 원/달러 현물환율을 예측한 결과 전통 모형에 비해 최적화된 다층 퍼셉트론 모형의 예측력이 우수하다는 것을 확인하였다. 그러나 동 연구는 일별 자료를 이용하여 3개월 뒤를 예측한 것이며 벤치마크 모형으로 우수한 예측력이 나타난 월별 ARIMA 모형이 아니라 예측력이 전혀 없는 일별 임의 보행 모형을 사용함으로써 실제 분석은 예측력이 있는지 없는지를 검정한 것이라고 할 수 있다.

III. 예측 기법 및 예측력 평가 방법

1. 예측 기법

본고의 목적은 대용량 자료를 대상으로 경제이론에 기반하지 않은 통계적 기법을 이용하여 원/달러 환율의 예측력을 평가하는 데 있다. 구체적으로는 선형 비구조 모형, 비선형 비구조 모형, 여러 예측치의 예측 조합 방식 등 세 가지 기법을 이용하여 예측을 진행하였다.

(1) 선형 모형

선형 모형을 통한 예측은 아래와 같은 회귀 모형을 이용하였다.

$$y_{t+h} = \beta_0 + \sum_{i=1}^n \beta_i x_{i,t} + u_{t+h} \quad (1)$$

여기서 y_{t+h} 는 h 기 앞 원/달러 환율, $\{x_{1,t}, \dots, x_{n,t}\}$ 는 n 개의 정보 변수 집합이며 u_{t+h} 는 오차항이다. 통상적인 경제 분석에서의 선형회귀모형은 u_{t+h} 에 대한 가정을 통해 β_i 의 일치추정량을 획득하는데 목표가 있으나 본고의 목표는 예측에 있으므로 일치추정량은 필요치 않으며 y_{t+h} 의 예측력을 가장 높일 수 있는 방법을 찾는 것이 중요하다. 일반적인 통상최소자승법은 여전히 효율적인 방법이나 본고에서와 같이 설명변수의 수가 많은 경우 다중 공선성 문제와 함께 표본 내 과적합(in-sample overfitting) 문제가 있어 표본 외 예측력이 떨어지는 문제가 있다. 이에 따라 본고에서는 대용량 자료에서의 과적합 문제를 완화하는 대표적 기법인 능형 회귀(Ridge regression), LASSO, Elastic Net 기법과 대용량 자료로부터 공통 요인을 추출하여 사용하는 동태 요인 기법 방식을 사용하였다. 능형 회귀는 잔차 제곱합(Sum of Squared Residual: SSR)을 최소화하는 OLS에 비해 식 (2)와 같이 잔차 제곱합과 회귀계수 값의 크기를 동시에 최소화하는 회귀계수 값을 추정하는 방식이다.

$$\hat{\beta}^{RI} \equiv \arg \min \sum_t^T e_t^2 + \lambda \sum_i^n \tilde{\beta}_i^2 \quad (2)$$

여기서 $\hat{\beta}^{RI}$ 는 능형 회귀 추정량이며 e_t 는 $\tilde{\beta}$ 을 식 (1)에 대입하였을 때의 잔차항이다. 능형 회귀 추정량은 수축 페널티 값(λ)에 따라 달라지는데, λ 가 0으로 갈수록 OLS 추정량과 같아지고 커질수록 $\hat{\beta}^{RI}$ 의 값이 작아지게 된다. 따라서 예측에 있어서 능형 회귀의 장점은 적절하게 λ 의 값을 선택하면 OLS에 비해 y_{t+h} 의 예측력을 높일 수 있다는 데 있다. LASSO는 능형 회귀와 유사하나 설명력이 낮은 변수들을 제거하는 수축(shrinkage) 추정량의 기능을 강화한 방법으로 아래와 같은 목적함수를 최소화하도록 회귀계수를 추정한다.

$$\hat{\beta}^{lasso} \equiv \arg \min \sum_{t=1}^T e_t^2 + \lambda \sum_{i=1}^n |\tilde{\beta}_i| \quad (3)$$

여기서 $\hat{\beta}^{lasso}$ 는 LASSO 추정량이다. 능형 회귀와 달리 절댓값 형태로 목적함수를 제시한 LASSO는 모서리해(corner solution)가 가능하여 설명력이 약한 변수들을 제거하는 효과가 있다. Elastic Net은 능형 회귀와 LASSO를 결합한 방식으로 아래의 목적함수를 최소화하도록 회귀계수를 추정한다.

$$\hat{\beta}^{EN} \equiv \arg \min \sum_{t=1}^T e_t^2 + \lambda_1 \sum_{i=1}^n |\tilde{\beta}_i| + \lambda_2 \sum_{i=1}^n \tilde{\beta}_i^2 \quad (4)$$

능형 회귀, LASSO, Elastic-Net으로부터 회귀식을 추정하기 위해서는 수축 페널티(λ)를 추정해야 한다. 일반적으로 λ 의 선택은 교차평가(cross validation) 기법을 많이 사용하나 이 방법은 시계열 예측에서의 표본 외 예측력과는 무관한 방법이다. 본고에서는 표본 외 예측력을 극대화하도록 축차적 교차평가(recursive cross validation) 방식을 사용하였다. 축차적 교차평가는 일반적인 교차평가를 시계열 예측 목적에 부합하도록 수정한 것으로 다음과 같은 절차를 따른다. 우선 특정 λ 값에 대해 $t = 1, \dots, t_0$ 의 표본자료를 이용하여 개별 회귀식을 추정한다.

추정된 계수를 토대로 $t_0 + h$ 기의 환율을 예측하고 실제치와의 차이인 예측오차를 저장한다. 다음으로 추정 기간을 $t_0 + 1$ 로 1기 늘리고 $t_0 + h + 1$ 기 예측 및 예측 오차를 저장한다. 이러한 과정을 표본 기간의 끝까지 수행한 후 저장된 $t_0 + h$ 부터 T 기까지의 예측 오차를 이용하여 RMSE 값을 시산한다. 동일한 작업을 모든 가능한 λ 값에 대해 시산한 뒤 가장 낮은 RMSE 값을 도출한 λ 를 수축 페널티로 사용하게 된다.

동태 요인 기법은 대용량 자료로부터 이들의 공통된 성격을 반영할 수 있는 공통 요인들을 추출하는 방식으로 기본적인 모형은 다음과 같다.

$$\begin{aligned} x_{i,t} &= \gamma_0 + \sum_{j=1}^p \gamma_j f_{j,t} + u_{i,t}, & i &= 1, \dots, n \\ f_{j,t} &= c_j + \rho_j f_{j,t-1} + \epsilon_{j,t}, & j &= 1, \dots, p \end{aligned} \quad (5)$$

여기서 $f_{j,t}$ 는 공통요인이며 $u_{i,t}$, $\epsilon_{j,t}$ 는 오차항들이다. 이 경우 환율 예측치는 아래와 같이 선형회귀를 통해 구할 수 있다.

$$y_{t+h} = \eta_0 + \sum_{j=1}^p \eta_j f_{j,t} + u_t \quad (6)$$

1세대 동태 요인 모형은 상태 공간 모형 형태인 식 (5)를 최우추정법으로 추정하고 칼만 필터를 통해 공통요인 $f_{p,t}$ 를 추정하였으나 n 이 클 때 추정해야 할 모수의 수가 너무 많아 글로벌 최적을 달성하는 데 어려움이 많다는 문제가 있다. 최근에는 n 이 상대적으로 클 경우 $x_{i,t}$ 의 가중평균이 공통 요인의 일치추정량이 된다는 점을 반영하여 주성분 분석을 통해 가중평균치를 구하거나 주성분 분석을 통해 추정된 공통 요인을 초깃값으로 하여 최우추정법을 다시 사용하는 방식이 주로 사용되고 있다(Stock and Watson, 2010). 본고에서는 주성분 분석을 이용하여 공통 요인을 추출한 뒤 이를 식 (6)에 적용하여 원/달러 환율을 예측하는 방식을 취하였다.

주성분 분석 방식을 이용한 동태 요인 모형에서는 최대 n 개의 공통 요인을

도출할 수 있다. 그러나 변수 개수 축소라는 처음의 목표에 부합하기 위해서는 적정 공통 요인의 개수를 선정해야 한다. 일반적으로 많이 사용하는 방법은 AIC(Akaike Information Criteria)의 공통 요인 버전인 Bai and Ng (2002)의 Information Criteria를 기준으로 선정하는 방법이다. 그러나 공통 요인을 이용하여 경제 분석 등을 진행할 경우에는 Bai and Ng(2002) 방법이 적절하나 AIC의 특성과 동일하게 이 방법이 표본 외 예측력을 극대화해 주는 수준은 아니다. 따라서 본고에서는 앞서 능형 회귀 등에서 수축 패널티를 시산했던 것과 동일하게 축차적 교차평가 방식으로 최적 공통 요인의 개수를 추정하였다. 즉, 1개의 공통 요인에 대해 앞선 설명과 같이 예측 오차 및 RMSE를 시산하고 동일한 과정을 2개의 공통 요인, ..., n_0 개의 공통 요인에 대해서 각각 시산한 다음 RMSE를 최소화하는 공통 요인의 개수를 최적 공통 요인 개수로 선정하는 방식이다.

(2) 비선형 모형

비선형 기법으로는 대표적인 기계학습 기법의 하나인 인공신경망 중 시계열 예측에 적합한 순환 신경망 방식을 사용하였다. 순환 신경망은 입력층, 히든층, 출력층이 구분된 기존 인공신경망과 달리 전기 히든층을 입력층에 포함해 시계열 자료의 시간 의존성을 기계학습 과정에 반영하는 방식이다. 즉, $x_t = (x_{1,t}, \dots, x_{n,t})'$ 를 입력층, h_t 를 히든층이라고 할 때 단순한 형태의 순환 신경망의 히든층과 최종 예측치는 다음과 같이 정의된다.

$$\begin{aligned}\hat{y}_{t+h} &= \omega_h h_t + w_{h0} \\ h_t &= f(w_1' h_{t-1} + w_2' x_t + w_0)\end{aligned}\tag{7}$$

여기서 w_h , ω_1 , ω_2 는 가중치 벡터, $f(\cdot)$ 은 활성화 함수이다. 즉, 순환 신경망은 신경망을 여러 개 복사해서 병렬 체인 구조로 연결하여 이전 신경망의 학습 결과를 현재 신경망의 학습에 사용하는 구조이므로 과거 시점의 데이터를 이용하여 현재를 예측할 수 있어 시계열 데이터를 처리하는데 매우 효과적인 알고리즘이다

(이권윤·이상부, 2018). 활성 함수가 선형일 경우 식 (7) 은 주성분 분석을 이용한 예측(식 (5), (6))과 유사하나 활성 함수가 비선형이라는 점에서 두 방식은 차별점을 가진다.

순환 신경망은 시계열 자료에 특화된 인공신경망 알고리즘이나 시차가 길어질수록 시계열 의존성이 급격하게 감소하는 문제가 발생한다. 이에 따라 본고에서는 시차에 따른 시계열 의존성을 강화한 LSTM 모델을 사용하여 환율을 예측하였다. LSTM에서 히든층은 다음과 같은 셀(C_t) 구조를 갖는 것으로 설정된다.

$$\begin{aligned} C_t &= f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \\ \tilde{C}_t &= \tanh(\omega_{c1}h_{t-1} + \omega_{c2}x_t + \omega_{c0}) \end{aligned} \quad (8)$$

여기서 $\tanh(\cdot)$ 은 hyperbolic tangent 함수이며 f_t, i_t 는 아래와 같이 설정된다.

$$\begin{aligned} f_t &= \sigma(\omega_{f1}h_{t-1} + \omega_{f2}x_t + \omega_{f0}) \\ i_t &= \sigma(\omega_{i1}h_{t-1} + \omega_{i2}x_t + \omega_{i0}) \end{aligned} \quad \begin{matrix} (9) \\ (10) \end{matrix}$$

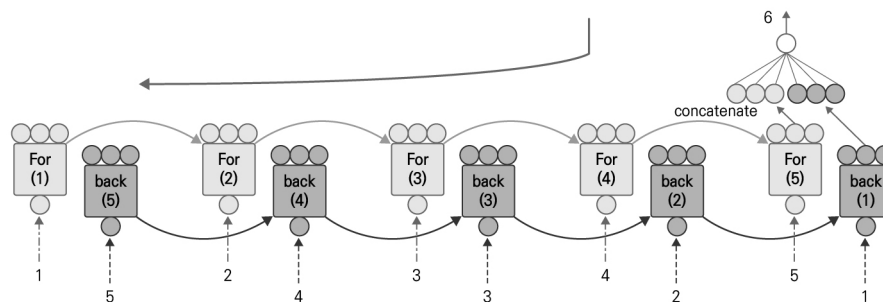
여기서 $\sigma(\cdot)$ 은 sigmoid 함수로 0 또는 1에 근사한 값을 가지게 된다. f_t 는 과거 정보를 버릴지 말지 결정하는 역할을 하게 되며 i_t 는 현재 정보의 반영 여부를 결정하게 되는데 전자를 forget gate, 후자를 input gate라고 한다. 즉, f_t 가 0에 가까울 경우 과거 셀의 정보를 버리게 되며 i_t 가 0에 가까우면 현재 층의 셀 정보를 버리게 되는 방식이다. 최종적으로 히든층 h_t 는 다음과 같이 설정된다.

$$\begin{aligned} h_t &= o_t \cdot \tanh(C_t) \\ o_t &= \sigma(\omega_{o1}h_{t-1} + \omega_{o2}x_t + \omega_{o0}) \end{aligned} \quad (11)$$

한편 LSTM을 구성하는 방식에 따라 여러 모형으로 구분되는데 해당 연구에서는 단층 단방향, 단층 양방향, 2층 단방향, 2층 양방향 총 4가지 모델을 사용하여 예측하고자 한다. 여기서 단방향과 양방향의 차이는 단방향의 경우 입력층에서

이전 데이터와의 관계를 학습하는데 양방향의 경우 이전 데이터와의 관계뿐만이 아니라 이후 데이터와의 관계까지도 학습한다. <그림 1>은 시차가 5인 단층 양방향 LSTM의 예를 보여주고 있다. 정방향의 경우 총 5개의 단계를 통해 최종치가 출력되고 있는데 각 단계마다 식 (8)-(10)의 과정을 거치게 되며 최종 단계인 For(5)에서 식 (11)을 통해 히든층이 도출되게 된다. 각 단계별로 시차 변수들이 새로 입력되게 되는데 For(1)에서는 5기 전 시차 변수가, For(2)에서는 4기 전 시차 변수가 입력되는 식이다. 즉 {1, 2, 3, 4, 5}는 각각 {5기전 시차 변수, ... 1기전 시차 변수}를 나타낸다. 한편 역방향의 경우는 반대로 1기전 시차 변수 → 2기전 시차 변수 → ... 5기전 시차 변수를 입력하여 최종 히든층을 도출하는 식으로 진행이 되며 최종적으로는 정방향 히든층과 역방향 히든층을 종합하여 예측치를 도출하게 된다.

〈그림 1〉 단층 양방향 LSTM (Single-Layer Bi-Directional LSTM)



주: For는 순방향으로의 정보전달을, back은 역방향으로의 정보전달을 의미한다.

출처: <http://blog.naver.com/chunjein>

Note: For means forward transmission of information while back is backward one.

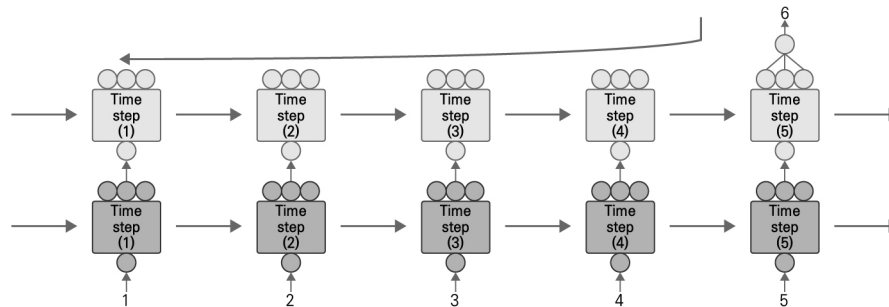
Source: <http://blog.naver.com/chunjein>

다층 LSTM에서 다층의 표현은 LSTM에서 사용된 레이어의 수를 말하며 LSTM 위에 또 하나의 LSTM을 연결하여 아래층의 모든 스텝에서의 출력이 위층의 각 스텝으로 전달되게 하는 것으로 <그림 2>에 나타나 있다. 단층 신경망에서는 시차 변수를 입력하여 식 (8)-(10)의 과정을 수행하게 되나 다층 신경망의 경우 시차 변수를 이용하여 식(8)-(10)의 과정을 통해 도출된 결과를 다시 입력치로 사용하여

동일한 과정을 한 번 더 반복하는 식이다.

에포크, 배치 크기 등의 하이퍼 파라미터와 정방향·역방향 레이어 수인 시차는 학습곡선(learning curve)을 통해 표본 내 과다 적합이나 과소 적합을 방지하는 수준을 판단하여 정하는 것이 일반적이다. 그러나 본고에서는 선형모형과 동일한 기준에서 표본 외 RMSE를 통해 예측력을 비교 분석하게 된다는 점을 감안하여 학습곡선 대신 선형모형에서 수축 페널티 설정과 동일하게 축차적 교차평가 과정을 통해 표본 외 RMSE를 가장 최소화할 수 있도록 파라미터와 시차를 설정하였다.

〈그림 2〉 2층 단방향 LSTM (Two layer Uni-Directional LSTM)



주: 단방향 LSTM을 두 층으로 쌓아 히든층의 셀 구조에 따른 정보분류 작업을 2회에 걸쳐 진행하는 방식이다.

출처: <http://blog.naver.com/chunjein>

Note: The figure shows that the every step information is processed twice.

Source: <http://blog.naver.com/chunjein>

(3) 예측조합

예측 조합은 다수의 개별 예측치들을 아래와 같이 종합하여 단일 예측치를 시산하는 방식이다.

$$\hat{y}_{t+h} = \sum_{s=1}^S \omega_s \hat{y}_{s,t+h} \quad (12)$$

여기서 \hat{y}_{t+h} 는 조합예측치, $\hat{y}_{s,t+h}$ 는 s번째 모형을 이용한 개별 예측치, ω_s 는

$\hat{y}_{s,t+h}$ 의 가중치이다. 본고에서는 단순 평균, 다듬어진 단순 평균 및 가중평균 방식을 모두 고려하였다. 단순 평균(Simple Average) 조합은 각 모형의 예측치에서 중요도를 고려하지 않고 산출한 평균값으로 예측치를 제시하는 것이며 다듬어진 평균(Trimmed Average) 방식은 개별 예측치 중 최댓값과 최솟값을 제외하고 단순 평균을 시산하는 방식으로 개별 예측치에서 특이치(outlier)를 제거한 뒤에 개별 예측 모형을 조합하는 방식이다. 가중평균은 개별 예측치의 예측력 정도에 따라 가중치를 다르게 하여 조합하는 방식이다. 가중치를 설정하는 방식은 여러 가지가 있으나 본고에서는 Hansen(2008)을 따라 개별 예측치의 MSE 및 RMSE를 이용하였다. 구체적으로 MSE를 이용할 때 개별 예측치 $\hat{y}_{s,t+h}$ 의 가중치는 다음과 같이 설정된다.

$$\omega_s = \frac{1}{MSE_s} / \sum_{i=1}^S \frac{1}{MSE_i} \quad (13)$$

여기서 MSE_s 는 $\hat{y}_{s,t+h}$ 의 MSE이다. RMSE를 이용한 가중치는 식 (13)에서 MSE 대신 RMSE를 입력하게 된다.

2. 데이터 및 예측력 평가 방식

본고에서 사용된 자료는 국내 금융, 국내 실물, 해외 금융, 해외 실물 4개의 영역으로 세분화하여 93개의 변수를 선별하였으며 모든 자료는 해당 월 말 기준에서 입력 가능한 수치를 기준으로 설정하였다. 이에 따라 금리, 통화량, 주가 등 실시간으로 입수가 가능한 금융변수들의 경우 해당 월의 공표 자료를 정보 변수로 사용했지만 산업 생산, 고용 등 실물 변수는 다음 달에 자료가 공표됨을 고려하여 1기 시차 변수를 정보 변수로 사용하였다. 또한 발표 시차가 긴 통화량, 한은 및 은행 계정 관련 자료는 2기 시차 변수를 정보 변수로 사용하였다. 회귀식에서 정보 변수들의 계수 부호들은 정보 변수 군의 구성에 영향을 받을 것으로 판단된다. 이를테면 국내 시장금리가 정보 변수에 포함될 경우 해외 시장금리의 상승은

내외금리차 상승을 유발하여 환율 상승 요인이 되나 국내 시장금리가 포함되지 않을 경우 반드시 내외금리차 상승을 의미하지는 않을 것이므로 계수의 부호는 글로벌 금리 동조성에 따라 달라질 것이다. 국내 유동성 확대 역시 물가 상승에 따른 환율 상승 요인으로 작용하나 여타국 유동성 변수 추가 여부 및 글로벌 유동성 동조 여부에 따라 부호가 달라질 것으로 예상된다. 반면 수출주도형 산업구조의 특성상 국내 및 해외 실물 변수의 개선은 환율 하락 요인으로 작용할 것으로 예상되며 국내 외화보유고 등 금융시장 안정성 관련 변수들은 환율 하락 요인이 될 것이다. 해외 금융시장 안정성 변수 역시 글로벌 금융 순환 및 거시건전성 개선 요인으로 국내 환율을 인하시키는 요인으로 작용할 것으로 예상된다. 추가로 글로벌 금융위기의 이상치(Outlier)를 고려하여 금융위기 더미 변수를 추가하였다. 선별된 모든 변수는 정상성을 확보하기 위해 ADF 검정을 시행한 후 로그 차분 혹은 차분을 거쳐 가공하였으며, 추가적 조치가 필요하다고 판단된 변수의 경우 2차 차분을 진행하였다. 계절조정 수치가 공표되는 경우 계절조정 값을 사용하였으며 기타 변수 중 계절성을 가지고 있는 것으로 의심되는 변수들은 X13-ARIMA 기법을 통해 제거하였다. 변수명과 변환 여부, 계절조정 여부는 부록의 <표 A-1>에 설명되어 있다.

2004년 1월부터 2019년 12월까지 총 192개월을 기간을 대상으로 분석하였으며 전체 자료의 70%인 2015년 1월까지의 자료를 추정예, 나머지 30%인 2015년 2월 이후의 자료를 표본 외 예측 및 예측력 평가에 사용하였다. 또한 2015년 1월 기준 직전 24개월을 축차 교차평가에 사용하였다. 즉, 능형 회귀, LASSO, Elastic-Net의 수축 페널티, 공통 요인의 개수, LSTM에서 시차의 개수들을 직전 24개월 기간에 대해 축차적 교차평가 방식으로 설정하였다. 수축 페널티의 상한은 10으로 설정하였으며 LSTM의 시차 상한은 6기로 설정하였다. 또한 예측 조합 시 가중치 시산을 위한 MSE 및 RMSE 값 역시 같은 기간 축차적 교차평가 방식으로 시산하였다. 페널티 계수나 LSTM 시차 시산과 달리 표본 외 예측력 평가에서는 축차 교차평가를 사용하지 않은 이유는 대용량 자료 및 LSTM 특성상 발생할 수 있는 표본 내 과적합 문제를 방지하기 위해서이다. 대용량 자료를 이용한 회귀분석이나 비선형 방식인 LSTM에서는 앞서의 정보 변수 개수 제한 등과 같은

조치를 취한다 해도 여전히 과적합 문제가 발생할 수 있다. 이러한 상황에서 축차 교차평가를 할 경우 $1 \dots t_0$ 기간 자료를 통해 학습 또는 추정한 결과로 $t_0 + 1$ 기를 예측하게 되는데 변수의 시간 종속성이 강할 경우 표본 내 과적합의 결과로 $t_0 + 1$ 기의 예측 오차도 과도하게 작게 평가될 수 있으며 따라서 표본 외 RMSE 역시 과소 추정될 우려가 있다. 이를 방지하기 위해 본고에서는 추정/학습 기간과 평가 기간을 완전히 분리하여 RMSE 과소 추정 문제를 방지하고자 하였다. 예측 시계(h)는 1, 2, 3, 6, 12개월로 설정하여 예측 시계별로 예측력을 따로 평가하였다.

추정을 위한 표본의 개수는 최소 108개에 해당하여 93개 변수 모두를 회귀분석에 사용하면 여전히 표본 내 과적합 문제가 발생할 우려가 있다. 이에 따라 본고에서는 각 예측 시계별로 정보 변수로서 예측 기여도가 뛰어난 30개 변수를 우선하여 선별한 후 해당 정보 변수들에 대해 선형 기법을 적용하는 방식을 취하였다. 즉, 각 예측 시계별로 환율의 자기 시차와 정보 변수 1개만을 포함한 회귀 모델을 설정하고 동일하게 2013. 2월~2015. 1월 기간에 대해 축차적 교차평가 방식으로 가장 작은 RMSE 값을 도출한 30개 변수를 추출한 뒤 이들을 실제 예측의 정보 변수로 활용하였다. 각 모형의 상대적 예측력을 판단하기 위한 벤치마크 모형으로는 ARIMA 모형을 사용하였다. AR 시차를 1기부터 6기까지 검토한 결과 기존 문헌들과 유사하게 ARIMA(3, 1, 0)의 RMSE가 가장 높은 것으로 나타나 이를 벤치마크로 사용하였다. 모형의 예측력 비교를 위해서는 가장 일반적인 손실함수인 RMSE를 활용하였다. 이와 함께 비대칭 손실함수인 Christoffersen and Diebold(1997)의 LinLin을 참고로 검토하였다.

IV. 분석 결과

1. 정보변수군

부록의 <표 A-1>은 각 예측 시계 별로 높은 예측력을 가지는 것으로 선별된 30개 정보 변수를 보여주고 있다. 예측 시계별 정보 변수들의 특징은 다음과 같다. 우선 모든 예측 기수에 공통으로 들어가는 변수는 글로벌 금융위기 더미 변수와 주택 전세가격지수이다. 우리나라는 글로벌 금융위기를 통해 원 달러 환율이 급등하였다. 원화 환율의 변동성은 글로벌 금융위기 이후 더욱 확대되었다. 원/달러 환율 변동성(전일 대비 변동률 기준)은 1990~97년 중 0.2% 수준에서 외환위기 이후 리먼 사태 이전까지 0.4%, 글로벌 금융위기 이후 0.6%로 증가하였다(서영경, 2011). 글로벌 금융위기가 원 달러 환율에 큰 영향을 미친 만큼 그 중요도가 크다. 이로 인해 모든 기수에 공통으로 포함되고 있는 것으로 판단된다.

1개월 후 예측에서 가장 많이 사용된 변수 군은 국내 실물 그룹이다. 국내 실물 변수 중에서도 물가 관련 지수, 산업 생산 관련 지수가 주를 이루고 있으며 이와 함께 주가지수도 다른 예측 시계와 비교해 환율 예측에 대한 정보 변수의 기능이 높은 것으로 나타났다. 일반적으로 경기선행지수라고 표현되는 주가지수는 단기 예측에서 영향이 큰 것으로 알려져 있다. 주가가 상승하는 경우 투자자들의 재산이 증식되고 이는 화폐에 대한 수요를 증가시켜 금리를 상승시키며 금리 상승은 자본 유입을 통해 환율을 하락시키는데(이근영, 2002) 초단기에는 이러한 경로가 상대적으로 크게 기여하고 있는 것으로 판단된다.

2개월 후 예측에서 가장 많이 사용된 변수 군 역시 국내 실물 그룹이다. 그중 수출입 관련 지수, 국내외 이자율 지수, 산업 생산 관련 지수가 주를 이루고 있어 1개월 후 예측과는 조금 상이한 모습을 보여주었다. 또한, 다른 기수와 달리 고용률, 국내와 미국의 산업생산지수, 무담보 콜금리가 30개 정보 변수에 포함되어 있다.

예측 시계의 설정이 3개월인 경우 해외 금융 그룹 변수들이 예측력 개선에 도움을 주는 것으로 나타났다. 주요 국가들의 본원통화, 외화 보유액, 중앙은행의 정책금리 등이 환율 예측의 RMSE를 가장 크게 낮추어 주는 것으로 나타났다. 또한 다른

시계와 달리 일본 주가지수가 포함되어 있으며 원/엔 환율, 엔/달러 환율의 영향을 받아 일본 경제와의 연관성이 높은 것으로 나타났다. 표본 외 예측 시기는 엔저 현상이 두드러졌던 시기이며 이러한 엔저에 따른 수출경쟁력을 악화 및 이로 인한 경상수지 악화가 원 달러 환율을 상승으로 이어졌을 것으로 예상된다.

6개월 후 후 예측에서 가장 많이 사용된 변수 군은 국내 금융 그룹이다. 국내 금융 중 주식시장 관련 지표들과 한국의 국내외 자산, 부채 변수들이 주를 이루고 있다. 다른 기수들과 비교하여 주요국들의 이자율과 산업생산지수가 변수로 포함되어 있다.

한편 12개월 후 예측에서 가장 많이 사용된 변수 군은 국내 금융 그룹이다. 다른 기수와 비교하여 한국의 국내외 자산, 부채 변수와 주요국들의 정책금리 지수들이 주를 이루고 있다.

이외에도 전반적으로 예측 기수에서 사용된 변수는 크게 통화량, 수출입, 물가, 국내외 이자율, 외화 보유액, 산업생산지수 등이 정보 변수로서 기능이 우수한 것으로 평가되었다. 환율의 결정 식에서 균형 환율은 각 국가의 통화량에 의존하며 자국 통화량이 증가할수록 환율은 상승하고 타국 통화량이 증가할수록 환율은 하락한다. 그리고 균형 환율은 각국의 산업 생산에 의존하는데 그 부호는 상대가격과 교역조건의 변화 두 가지 측면을 동시에 고려해야 한다. 상대가격의 측면에서 자국의 산업 생산이 증가하면 자국 재화의 상대가격이 하락하고 자국 통화가치는 상승한다. 만일 효용함수가 동차성을 만족하면 자국의 산업 생산이 증가할수록 교역조건이 상승하지만, 그에 해당하는 상승 폭은 상대가격의 하락에 비하여 작다. 따라서 자국의 산업 생산이 증가하면 환율을 하락시키고 자국 통화의 가치는 상승한다는 점에서 산업 생산의 정보 변수로서의 유용성이 있다고 하겠다. 수출입 금액도 환율 변동에 영향을 미친다. 해당국의 수출이 증가하면 외환 공급이 늘어나 환율이 하락(자국 통화가치의 상승)하고 소득증가 등으로 수입이 늘어나면 외환 수요가 증가함에 따라 환율이 상승(자국 통화가치의 하락)한다.

2. 개별 모형 예측력 평가

〈표 1〉은 4개의 선형 기법을 이용하여 원/달러 환율을 예측한 결과를 보여주고 있다. 1개월 후 환율 예측에 있어서는 대용량 자료를 이용한 선형 모형의 RMSE가 벤치마크 모형인 ARIMA보다 낮은 것으로 나타나 선형모형 환율 예측 모형에서 대용량 자료 활용의 유용성을 확인할 수 있었다. ARIMA 모형의 RMSE가 1.64인 반면 대용량 자료를 사용한 선형 모형들의 RMSE는 1.17~1.47로 RMSE가 11%~29% 개선된 것으로 분석되었다. 개별 모형 중에는 공통 요인을 설명변수로 통상최소자승법으로 추정된 모형의 RMSE가 가장 작은 것으로 나타났다. 반면 능형 회귀, LASSO, Elastic-Net의 RMSE들은 대체로 유사한 모습을 보이거나 능형 회귀의 RMSE가 소폭 낮은 것으로 나타났다. 2~3개월 후 환율 예측의 능형 회귀와 DFM RMSE가 여전히 벤치마크 모형보다 낮은 것으로 나타났으나 RMSE의 차이는 1개월 후에 비해 다소 줄어드는 것으로 분석되었다. 2개월 후 ARIMA 모형의 RMSE가 1.74인 반면 두 모형의 RMSE는 1.60~1.72이었으며 3개월 뒤 예측에서도 벤치마크 모형 1.73에 비해 대용량 자료 기반 모형은 1.52~1.66의 RMSE를 나타내고 있다. 이는 경제 변수 간의 구조적 관계에 기반하지 않고 대용량 자료의 통계적 기법을 이용할 경우 주로 단기 전망에 유용성이 높다는 기존의 분석들과도 궤를 같이한다고 볼 수 있다. 반면 LASSO와 Elastic-Net의 경우 2개월 시계 이후에서는 벤치마크 모형과 큰 차이를 나타내지 않아 상대적으로 예측력이 떨어진 것으로 나타났다. 한편 대표적인 환율 결정식인 이자율 평형이론 및 구매력평가설을 반영하여 기존 연구들과 같이 한미 금리 기준 모형 및 한미 물가 기준 모형을 기반으로 한 회귀 모형을 이용한 예측도 진행해 보았다. 이들 모형의 RMSE 값은 1개월 시계에서 1.71~1.73, 3개월 시계에서 1.72~1.93, 6개월 시계에서 1.72~1.78로 나타나 ARIMA 모형 및 본고의 모형에 비해 낮은 예측력을 보이는 것으로 나타났다. 한편 위에서의 모형을 토대로 정보 변수들의 1기 시차를 설명변수에 추가한 모형으로도 환율 변동의 예측을 추가로 진행하였으나 결과에는 큰 차이가 없었으며 상당 부분 모형에서 RMSE가 오히려 상승하였다.

〈표 1〉 선형 모형의 RMSE (Model-specific RMSE for linear models)

예측 시계(h)	ARIMA(3,1,0)	Ridge	Lasso	E-Net	DFM
1	1.6437	1.2624	1.469	1.4676	1.1718
2	1.7451	1.6122	1.7184	1.7184	1.6032
3	1.7293	1.639	1.6594	1.6465	1.5256
6	1.7045	1.694	1.6586	1.6571	1.6214
12	1.6551	1.6707	1.6313	1.6307	1.5316

주: 2004.1월~2015.1월까지의 자료를 이용하여 추정된 뒤 2015.2월부터 2019.12월까지의 자료에 대해 표본 외 예측을 진행하였다. Ridge, LASSO, Elastic-Net의 수축 페널티는 2013.2~2015.1월 기간에 대해 축차적 교차평가를 통해 추정하였다. DFM의 요인 개수는 예측 시계별로 22, 4, 24, 4, 18개이다.

Note: The models are estimated using the data spanning from 2015.2 through 2015.1 and RMSE is calculated using the forecasts for the period of 2015.2 through 2019.12. Shrinkage penalties are calculated using the recursive cross validation for the period of 2013.2 through 2015.1. The numbers of factors of DFM are 22, 4, 4, 18 for each forecast horizon, respectively.

〈표 2〉는 예측 시계별 LSTM 모형을 이용한 예측의 RMSE 값을 보여주고 있다. 예측 결과 1기 후, 2기 후 예측에서는 단층 양방향 모델을 제외한 나머지 3가지 모델이 ARIMA(3, 1, 0) 모형보다 좋은 예측력을 나타냈으며, 3기 후 예측에서는 단층 단방향 모델만이 좋은 예측력을 나타냈다. 6기 후와 12기 후 예측에서는 4가지 모델 모두 ARIMA(3, 1, 0) 모형을 이기지 못하는 결과를 보였다. 선형모형과 비교하였을 때 LSTM 모형은 어떠한 설정에서도 선형 모형보다 높은 예측력을 나타내지 못하고 있다. 특히 동일한 설명변수를 사용하고 있는 DFM과 비교할 때도 거의 모든 예측 시계에서 비선형 방식의 예측력이 더 열등한 것으로 나타나고 있다. 기존 연구에서도 비선형 기계학습의 예측력이 선형모형에 비해 낮은 예측력을 보이는 경우는 종종 있었다. (Gonçalves and João, 2018, Massini, Mdeiros, and Mendes., 2021) 상대적으로 낮은 예측력 이유 중의 하나는 기계학습의 유용성을 충분히 활용할 수 있을 만큼의 학습 기회가 주어지지 않는다는 점을 들 수 있다. 기계학습은 충분한 데이터를 통해 비선형 패턴을 정교하게 추론할 수 있을 때 비선형 모형을 통한 예측력을 크게 높일 수 있다는 장점이 있다. 그러나

월별 또는 분기 경제, 금융 시계열 자료들은 표본의 수가 제한되어 있어 비선형 모형을 활용할 만큼의 충분한 학습이 이루어지지 못할 가능성이 있는 것이다. 본고에서도 훈련 자료의 표본 수가 100여 개에 불과해 실제 빅데이터와 같은 형식의 훈련이 이루어질 수 없다는 점도 LSTM 모형의 제약으로 작용한 것으로 평가된다.

〈표 2〉 LSTM 모형별 RMSE (RMSEs by LSTM types)

예측 시계(h)	ARIMA(3,1,0)	단층 단방향	단층 양방향	2층 단방향	2층 양방향
1	1.6437	1.6349	1.6616	1.6147	1.636
2	1.7451	1.7466	1.7401	1.7312	1.7775
3	1.7293	1.7129	1.8406	1.7944	1.789
6	1.7045	1.8167	1.857	1.8525	1.7529
12	1.6551	1.8371	1.7877	1.7189	1.7344

주: 2004.1월~2015.1월까지의 자료를 이용하여 추정한 뒤 2015.2월부터 2019.12월까지의 자료에 대해 표본 외 예측을 진행하였다. 시차는 2013.2~2015.1월 기간에 대해 축차적 교차평가를 통해 추정하였다.

Note: The models are estimated using the data spanning from 2015.2 through 2015.1 and RMSE is calculated using the forecasts for the period of 2015.2 through 2019.12. Lag lengths are calculated using the recursive cross validation for the period of 2013.2 through 2015.1.

한편 LSTM에서 학습 커브도 평가하였으나 1개월 시계와 2개월 시계 모두에서 트레이닝 곡선과 검증 곡선이 수렴하고 있지 않는 것으로 나타났다. 따라서 학습에 충분치 못한 데이터의 양으로 인한 예측력 저하 가능성을 시사하고 있다. 한편 동일한 모형들에 대해 비선형 손실함수인 LinLin 값을 시산한 결과는 〈표 A-2〉에 제시되었다. LinLin의 경우 분위 함수를 사용하는 경우가 최적 예측치를 제공하는 것으로 알려져 있어 본고에서의 모형 및 ARIMA 모형 모두 최적값을 제공하지는 않을 것으로 예상된다. 그러나 고려된 모형들 사이에서 비교할 때 LinLin 손실함수 값 역시 본고의 모형들이 ARIMA에 비해 우수한 결과를 시현하였다.

3. 예측조합의 예측력 평가

〈표 3〉은 예측 조합을 이용한 방식의 RMSE 값을 보여주고 있다. 먼저 모든 예측 기수에서 단순 평균 조합, 다듬어진 평균 조합, MSE 가중평균 조합, RMSE 가중평균 조합 4가지 모형 모두 ARIMA(3, 1, 0) 모형보다 좋은 예측력을 나타냈다. 개별 모형과 비교할 때 예측 조합은 모든 LSTM 모형보다는 우수한 RMSE 값을 보이고 있고 선형 기법과 비교할 때 조합 방식과 상관없이 RMSE 값이 낮은 모형의 결과와 근사한 것으로 나타났다. 선형 기법이 예측 시계에 따라 상이한 결과를 보이고 있음을 고려할 때 예측 조합 방식을 사용하면 모든 예측 시계에서 우수한 예측력을 보여 활용도가 가장 높은 것으로 판단된다.

〈표 3〉 예측조합의 RMSE (RMSE of the Predictive combination)

예측 시계(h)	ARIMA(3,1,0)	단순평균	다듬어진 평균	MSE 가중평균	RMSE 가중평균
1	1.6437	1.3065	1.3209	1.2704	1.288
2	1.7451	1.6378	1.6538	1.6331	1.6354
3	1.7293	1.6043	1.6095	1.5997	1.602
6	1.7045	1.6296	1.6397	1.6286	1.6291
12	1.6551	1.6046	1.6071	1.6004	1.6025

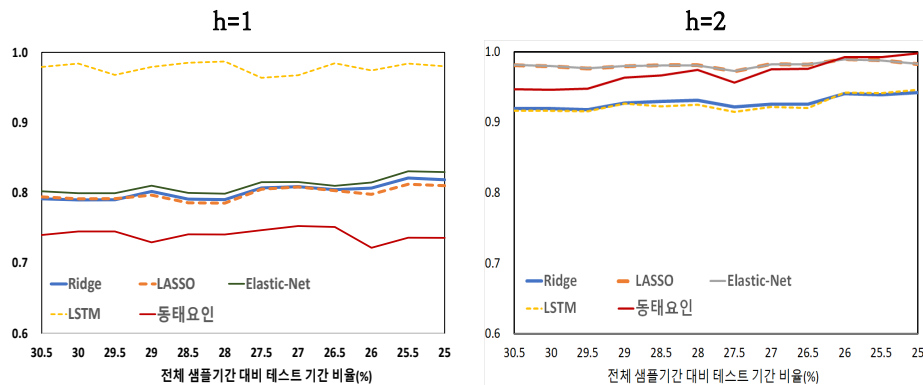
주: 2004.1월~2015.1월까지의 자료를 이용하여 추정한 뒤 2015.2월부터 2019.12월까지의 자료에 대해 표본 외 예측을 진행하였다. 가중치 시산은 2013.2~2015.1월 기간에 대해 축차적 교차평가 방식으로 시산된 MSE를 이용하였다.

Note: The models are estimated using the data spanning from 2015.2 through 2015.1 and RMSE is calculated using the forecasts for the period of 2015.2 through 2019.12. Weights are calculated using the recursive cross validation for the period of 2013.2 through 2015.1.

한편 결과의 강건성을 판단하기 위해 추정 기간과 표본 외 예측 기간을 조정하면서 동일한 분석을 진행해 보았다. 벤치마크 모형에 대비 RMSE 개선 정도에 있어서는 소폭 차이가 있었으나 모든 경우에 있어서 선형 모형 및 예측 조합이 벤치마크 모형에 비해 우수하다는 점은 일관되게 유지되고 있었다.

〈그림 3〉은 예측력이 우수했던 1기 및 2기 예측시계에 대해 전체 표본 기간 중 테스트 기간의 비율을 변화시켜 가며 예측의 RMSE와 ARIMA 예측의 RMSE 간 비율을 보여주고 있다. 비율이 1을 밑돌게 되면 대용량자료 기반 모형의 RMSE가 ARIMA의 경우보다 낮게 되어 더 우수한 예측력을 보여준다는 것을 의미하는데 그림에서 보는 것처럼 테스트 기간 변동에도 큰 차이 없이 대용량 기반 모형의 상대적 우수성이 유지되고 있음을 알 수 있다.

〈그림 3〉 테스트 기간 변동에 따른 대용량자료 기반 예측과 ARIMA간 RMSE 비율(RMSE Ratio of large data based forecasts and ARIMA forecasts across testing periods)



주: 전체 샘플기간 대비 표본 외 예측을 위한 테스트 기간의 비율을 25%에서부터 30.5%까지 변동시켰을 경우의 RMSE 비율(데이터마이닝 RMSE/벤치마크 RMSE)로 동 비율이 1이면 데이터마 이닝의 RMSE가 벤치마크의 경우와 동일하며 1보다 작으면 더 낮은 RMSE값이 시현됐음을 의 미한다.

Note: The figure shows the ratio of RMSE of our models and the benchmark one across different training sizes. Thus our models performs better than the benchmark models if the ratio is less than one.

V. 맺음말

최근에는 국가 간 자본 이동이 활발해지면서 환율의 변동폭이 커지고 있다. 예상치 못한 환율의 급변동은 자본의 흐름에 큰 영향을 미쳐 경제를 불안정하게 만든다. 이에 환율에 대한 연구를 통해 금융 안정을 도모하려는 노력이 필요하다. 본고에서는 대용량 거시, 금융 정보 변수를 활용하여 구조적 모형에 근거하지 않고 통계적 기법만을 사용하여 원/달러 환율의 변동을 예측하는 모형을 평가해 보았다. 연구 결과를 요약하면 다음과 같다. 분석 결과 예측시계 3개월 이하의 초단기에서는 대용량 자료에 기반한 예측 모형이 기존 분석에서 가장 우수한 것으로 분석되는 ARIMA 모형에 비해 예측력이 우수한 것으로 분석되었다. 다만 1개월 후의 예측에서는 매우 우수한 모습을 보였으나 2개월, 3개월 후의 예측에서는 상대적 우수성이 다소 감소하였다. 개별 모형을 비교할 때 DFM 모형과 능형 회귀 모형이 상대적으로 우수하였으나 예측시계에 따라서 다소 상이한 예측력을 나타내었다. 반면 비선형 기법인 LSTM의 예측력은 선형모형에 비해서는 다소 낮게 분석되었다. 개별 예측치를 조합할 경우 조합 방식과 무관하게 초단기 예측에서 일관되게 벤치마크 모형보다 우수한 예측력을 시현하여 가장 안정적인 예측력을 보일 수 있는 것으로 분석되었다.

대용량 자료에 기반한 분석의 예측력은 확인되었으나 향후 다양한 방법으로 개선할 경우 예측력을 개선할 여지는 여전히 있는 것으로 판단된다. 먼저 변수의 설정에 관한 문제이다. 지금까지 환율을 예측하기 위한 많은 연구가 진행됐지만, 환율을 예측하기 위해 꼭 필요한 변수에 대한 정보는 여전히 부족하다. 따라서 대용량 자료를 통해 예측을 진행하는 본 연구는 초기에 93개의 자료를 수집한 후 이 중에서 예측 기수별로 사용될 변수 30개를 추출하였는데 시작을 변수 93개로 제한하는 것이 아니라 더 다양한 변수를 포함함으로써 특정되지 않은 여러 변수와의 관계를 맺고 있는 환율에 대한 예측 성능을 향상할 수 있을 것으로 판단된다. 또한, LSTM만을 사용하였던 본고에 비해 보다 다양한 비선형 기법을 시도할 필요가 있을 것으로 생각된다. 학습 커브를 볼 때 LSTM의 예측력을 극대화하기에는 여전히 월별 데이터의 수가 충분치 않은 부분도 있었으나 LSTM 자체의 편의 가능성도

있는 것으로 보이기 때문이다. 이와 함께 학습의 기회를 높이기 위해서는 샘플 기간을 늘이기 위해 비선형을 대상으로 자료의 범위를 다소 좁혀서 분석을 진행하는 것도 의미가 있을 것으로 생각된다.

또한 금융 안정에 있어 외환시장의 역할이 더욱 중요해질 수 있음을 고려할 때 보다 긴 예측시계에서도 대용량 자료를 이용하여 예측력을 개선할 수 있는 방안을 고려할 필요가 있다. 금융 시스템 리스크는 선제적 대응이 무엇보다 중요하며 따라서 외환시장의 불안정성을 일찍 포착해야 할 필요성이 더욱 커지기 때문이다.

참고 문헌

- 김영철·이현준·김지우·안재준, “스왑포인트 결정요소를 이용한 머신러닝 기반의 원/달러 환율 예측모형에 관한 연구: 다층퍼셉트론의 최적 구조 탐색을 중심으로,”『한국 데이터 정보과학회지』제29권, 제1호, 2018, pp. 203-216. (DOI : <http://dx.doi.org/10.7465/jkdi.2018.29.1.203>)
- 방성혁·배석현·박현규·전명중·김제민·박영택, “순환신경망 기반의 사용자 의도 예측 모델,”『정보과학회 논문지』제45권, 제4호, 2018, pp. 360-369. (DOI : <https://doi.org/10.5626/JOK.2018.45.4.360>)
- 서영경·성광진·김동우, “원/달러 환율 변동성이 큰 배경과 시사점,”『BOK 경제 브리프』한국은행, 2011, pp. 1-33.
- 서종덕, “데이터 마이닝 기법을 이용한 환율예측: GARCH와 결합된 랜덤 포레스트 모형,”『산업경제연구』제29권, 제5호, 산업경제연구, 2016, pp. 1607-1628. (UCI : I410-ECN-0101-2017-323-001648316)
- 오문석·이상근, “시계열모형에 의한 환율 단기예측력 비교,”『금융학회지』제4권, 제1호, 1999, pp. 27-48. (UCI : I410-ECN-0102-2009-320-008218829)
- 오문석·이상근, “환율결정모형의 원 / 달러환율 예측력 비교,”『경영학연구』제29권, 제4호, 2000, pp. 711-722. (UCI : I410-ECN-0102-2009-320-006810654)
- 이권윤·이상부, “RNN을 이용한 범용 예측 시스템 구현,”『한국정보기술 학회 논문지』제16권, 제10호, 2018, pp. 1598-8619. (DOI : <https://doi.org/10.14801/jkiit.2018.16.10.11>)
- 이근영, “환율과 주가간의 인과관계분석,”『경제학연구』제50권, 제4호, 2002, pp. 231-266. (UCI : I410-ECN-0102-2009-320-004340324)
- 이상래, “환율예측모형의 비교연구,”『한국과학기술원』, 2005. (URL : <http://hdl.handle.net/10203/52242>)

- 조우길·모수원, “환율의 통화론적 모형에 의한 장단기예측,” 『무역학회지』 제21권, 제1호, 1996, pp. 107-124.
(UCI : I410-ECN-0102-2009-320-006849500)
- 한정아·안창호, “시계열모형을 이용한 원/달러 환율 예측모형 비교연구,” 『융복합지식 학회논문지』 제7권, 제4호, 2019, pp. 69-78.
(DOI : <https://doi.org/10.22716/sckt.2019.7.4.052>)
- Bai, J., and S. Ng., “Determining the Number of Factors in Approximate Factor Models,” *Journal of Econometrica*, Vol. 70, No. 1, 2002, pp. 91-221. (DOI : <https://doi.org/10.1111/1468-0262.00273>)
- Beckmann J., and R. Schüsslerde., “Forecasting exchange rates under parameter and model uncertainty,” *International Money and Finance*, Vol. 60, 2016, pp. 267-288.
(DOI: <https://doi.org/10.1016/j.jimonfin.2015.07.001>)
- Christoffersen, B.F., and Diebold, F.X., “Optimal Prediction Under Asymmetric Loss,” *Econometric Theory*, Vol. 13, 1997, pp. 808-817. (DOI: <https://doi.org/10.1017/S0266466600006277>)
- Dautel, A.J., Härdle, W.K., Lessmann, S., and H. Seow., “Forex exchange rate forecasting using deep recurrent neural networks,” *Digital Finance*, Vol. 2, 2020, pp. 69-96.
(DOI: <https://doi.org/10.1007/s42521-020-00019-x>)
- Gonçalves, V. and R. João, “Forecasting economic time series using chaotic neural networks,” *XV Encontro Nacional de Inteligência Artificial e Computacional Conference*, 2018.
(DOI: <https://doi.org/10.5753/eniac.2018.4470>)
- Hansen, B.O., “Least Squares Forecast Averaging,” *Journal of Econometrics*, Vol. 146, 2008, pp. 342-350.
(DOI: <https://doi.org/10.1016/j.jeconom.2008.08.022>)
- Ince, O., “Forecasting exchange rates out-of-sample with panel methods

- and real-time data,” *Journal of International Money and Finance*, Vol. 43, 2014, pp. 1-18.
(DOI: <https://doi.org/10.1016/j.jimonfin.2013.12.004>)
- Leung, M.T., Chen, A., and H. Daouk, “Forecasting exchange rates using general regression neural networks,” *Journal of Computers and Operations Research*, Vol. 27, 2000, pp. 1093-1110. (DOI: [https://doi.org/10.1016/S0305-0548\(99\)00144-6](https://doi.org/10.1016/S0305-0548(99)00144-6))
- Markova, M., “Foreign exchange rate forecasting by artificial neural networks,” *Journal of AIP Conference Proceedings*, 2019.
(DOI: <https://doi.org/10.1063/1.5130812>)
- Massini, R.P., Mdeiros, M.C., and E.F., Mendes., “Machine Learning Advances for Time Series Forecasting,” *arXiv Working Paper*, Cornell University, 2021. (URL: <https://arxiv.org/abs/2012.12802>)
- Meese R and Rogoff K., “Empirical Exchange Rate Models of the 1970's: Do They Fit Out of Sample?,” *Journal of International Economics*, February, No. 14, 1983, pp. 3-24.
(DOI: [https://doi.org/10.1016/0022-1996\(83\)90017-X](https://doi.org/10.1016/0022-1996(83)90017-X))
- Panda, C., and V. Narasimhan, “Forecasting exchange rate better with artificial neural network,” *Journal of Policy Research*, Vol. 29, 2007, pp. 227-236.
(DOI: <https://doi.org/10.1016/j.jpolmod.2006.01.005>)
- Stock, J.H., and M.W. Watson, “Dynamic Factor Models,” Prepared for the *Oxford Handbook of Economic Forecasting*, M. Clements and D. Hendry(eds.), Oxford University Press, 2010.
(DOI: <https://doi.org/10.1093/oxfordhb/9780195398649.013.0003>)

〈표 A-1〉 예측시계별 정보변수

h=1	h=2	h=3	h=6	h=12
원/달러	원/달러	원/달러	원/달러	원/달러
LF 평잔	협의통화 평잔	광의통화 평잔	LF 평잔	본원통화 평잔
국내 부채	국외 부채	LF 평잔	국내 부채	국내 부채
국외 부채	한국은행 기준금리	L 말잔	국외 자산	국내 자산
외화예금	기업대출	국내 부채	요구불예금	국외 부채
KOSDAQ_증가	무담보콜금리	국외 부채	저축성예금	한국은행 기준금리
KOSPI_배당수익률	국고채(3년)	요구불예금	외화예금	무담보콜금리
KOSPI_증가	수출물가지수	원/엔	원화예금	국고채권
외환보유액	주택매매가격	전산업 매출실적	KOSPI 배당수익률	생산자물가지수
공급물가지수	지역별 원화 결제 수출 전체	수출(관세청)	원/엔	공급물가지수
수출물가지수	지역별 원화 결제 수출 미국	수출물량지수	수출물가지수	소비자물가지수
수입물가지수	지역별 원화 결제 수출 중국	소득교역조건지수	주택매매가격	수출물가지수
지역별 원화 결제 수출 중국	수출금액지수	지역별 원화 결제 수출 일본	업황전망	수입물가지수
수출금액지수	채산성실적	자금사정 실적	매출전망	주택전세가격
수출물량지수	매출전망	자금사정 전망	채산성전망	지역별 원화 결제 수출 일본
수입물량지수	경제심리지수	경제심리지수	자금사정 전망	전산업 매출실적
경제심리지수	고용률	고용률	고용률	경제심리지수
전산업생산지수	본원통화 유로	엔/달러	엔/달러	전산업생산지수
산업생산지수 한국	본원통화 미국	본원통화 호주	미국 DOWJONES	미국 NASDAQ
본원통화 호주	외환보유액 호주	본원통화 유로	EURO STOXX	중국 SHCOMP
외환보유액 호주	외환보유액 미국	외환보유액 영국	일본 NIKKEI	본원통화 호주
외환보유액 영국	T/Bill(6M)	T/Bill(6M)	본원통화 유로	영국정부채(10년)
외환보유액 미국	£ LIBOR(3M)	EURO-LIBOR(3M)	T/Bill(6M)	일본정부채(10년)
T/Bill(6M)	정책금리 중국	정책금리 중국	일본정부채(10년)	£ LIBOR(3M)
T/Note(5년)	국제수입 중국	정책금리 유로	정책금리 유로	정책금리 영국

h=1	h=2	h=3	h=6	h=12
영국정부채(10년)	국제수입 미국	중앙은행 정책금리 영국	중앙은행 정책금리 영국	국제수입 미국
국제수입 영국	국제수출 미국	국제수입 영국	국제수입 영국	국제수출 영국
국제수입 미국	산업생산지수 일본	국제수출 영국	산업생산지수 영국	국제수출 미국
산업생산지수 미국	산업생산지수 미국	산업생산지수 미국	산업생산지수 미국	생산자물가지수 영국
dummy	dummy	dummy	dummy	dummy

〈표 A-2〉 예측모형별 LinLin (Model Specific LinLins, $\alpha = 0.7$)

선형모형

예측 시계(h)	ARIMA(3,1,0)	Ridge	LASSO	E-Net	DFM
1	0.6853	0.4871	0.6053	0.6047	0.4171
2	0.7185	0.6417	0.7020	0.7022	0.6076
3	0.7103	0.6750	0.6720	0.6603	0.5927

LSTM

예측 시계(h)	ARIMA(3,1,0)	단층 단방향	단층 양방향	2층 단방향	2층 양방향
1	0.6853	0.7092	0.6856	0.6972	0.6561
2	0.7185	0.7050	0.6578	0.6685	0.6631
3	0.7103	0.6945	0.8055	0.6981	0.7539

예측조합

예측 시계(h)	ARIMA(3,1,0)	단순평균	다듬어진 평균	MSE 가중평균	RMSE 가중평균
1	0.6853	0.5152	0.5200	0.4935	0.5038
2	0.7185	0.6381	0.6503	0.6357	0.6369
3	0.7103	0.6458	0.6486	0.6432	0.6446

주: 1) 2004.1월~2015.1월까지의 자료를 이용하여 추정한 뒤 2015.2월부터 2019.12월까지의 자료에 대해 표본 외 예측을 진행하였다. 시차는 2013.2~2015.1월 기간에 대해 축차적 교차평가를 통해 추정하였다.

$$2) \text{LinLin} = \alpha \epsilon_{t+h} 1_{[\epsilon_{t+h} > 0]} + (1-\alpha) \epsilon_{t+h} 1_{[\epsilon_{t+h} < 0]}$$

Note: 1) The models are estimated using the data spanning from 2015.2 through 2015.1 and RMSE is calculated using the forecasts for the period of 2015.2 through 2019.12. Lag lengths are calculated using the recursive cross validation for the period of 2013.2 through 2015.1.

$$2) \text{LinLin} = \alpha \epsilon_{t+h} 1_{[\epsilon_{t+h} > 0]} + (1-\alpha) \epsilon_{t+h} 1_{[\epsilon_{t+h} < 0]}$$

Forecasting Won/Dollar Exchange Rate using Large Macroeconomic and Finance Data Set*

Jeon, Chan Woo**, Park, Min Ji***, Lee, Ji Won****, Lee, Dong Jin*****

〈Abstract〉

This paper examines the performance of forecasting the won/dollar exchange rate using a large set of macroeconomic and finance data. We consider ridge regression, least absolute shrinkage and selection operator, elastic-net, and dynamic factor model as well as a long short-term memory (LSTM) recurrent neural network. We also examine forecast combinations of single data mining forecasts. Finance and macroeconomic data from 93 months from January 2004 to December 2019 are used as information variables. We find that forecasts using a large data set perform better than the benchmark ARIMA based forecasts for periods of 3 months or less ahead. Linear methods such as Ridge, LASSO, Elastic-net, and factor model generally perform better than LSTM, while the relative forecasting performances of linear models differ across forecast horizons. The forecast combinations perform similar to the best single forecasts in all short term forecast horizons, which indicates the benefits of using combination methods rather than individual forecasts.

Key words: Ridge Regression, Large Data, Artificial Neural Network, won/dollar exchange rate, Predictive combination, LASSO, Elastic-Net

JEL: C53, C55, F31

Date of Receipt (Oct 19, 2021), Date of Revision (Nov 22, 2021), Date of Acceptance (May 24, 2022)

* This work was supported by SMU-LINC+.

** (First Author) BA, Department of Economics and Finance, Sangmyung University, jcw050@naver.com

*** (Co-Author) undergraduate student, Department of Economics and Finance, Sangmyung University, 4ekfo@naver.com

**** (Co-Author) undergraduate student, Department of Economics and Finance, Sangmyung University, supwon0305@naver.com

***** (Corresponding Author) Professor, Department of Economics and Finance, Sangmyung University, Seoul, rheedj@smu.ac.kr, +82-2-2287-6123